Análise Preditiva de Desempenho Escolar no ENEM 2023 baseada em Fatores Socioeconômicos

João Pedro Lopes Mendes[1], Luis Felipe Cunha [1]

[1]Faculdade de Computação e Informática (FCI)
Universidade Presbiteriana Mackenzie – São Paulo, SP – Brasil

Faculdade de Computação e Informática (FCI) – Universidade Presbiteriana Mackenzie – São Paulo, SP – Brasil

{10400793@mackenzista.com.br, 10419514@mackenzista.com.br}

Link para o repositório do Github:
https://github.com/JoaoLopesMendes/Projeto-IA-ENEM-2023

Resumo. *O presente projeto propõe o desenvolvimento de um modelo de Inteligência Artificial para prever o desempenho acadêmico de candidatos do ENEM 2023. Utilizando a* ***Opção Framework (scikit-learn)****, o estudo analisa como variáveis como renda familiar, escolaridade dos pais e acesso à tecnologia influenciam as notas finais. A metodologia envolve análise exploratória de dados (EDA) em uma amostra dos microdados do INEP, visando identificar padrões de desigualdade educacional para apoiar futuras políticas públicas de suporte pedagógico.*

Palavras-chave: *Inteligência Artificial; Microdados ENEM; Análise Preditiva; Educação; Desigualdade Socioeconômica.*

1.Introdução

1.1. Contextualização e Justificativa

O Exame Nacional do Ensino Médio (ENEM) consolidou-se como o principal mecanismo de acesso ao ensino superior no Brasil (INEP, 2025). Contudo, o desempenho acadêmico dos participantes não é um fenômeno isolado, sendo profundamente influenciado por fatores socioeconômicos (BONAMINO *et al.,* 2010). Nesse contexto, estudos empíricos indicam que existe uma correlação acentuada entre o acesso a recursos

educacionais e tecnológicos, a renda familiar e a proficiência nas provas de competências básicas (BARROS *et al.,* 2001).

Apesar da disponibilidade dos microdados públicos, há uma carência de ferramentas que transformem esses dados brutos em inteligência preditiva capaz de nortear políticas de equidade. Este projeto justifica-se pela necessidade de aplicar técnicas de *Machine Learning* para identificar, de forma automatizada, quais fatores socioeconômicos funcionam como os principais preditores de risco de baixo desempenho, permitindo uma visão analítica sobre as desigualdades educacionais no país.

1.2. Objetivos

O objetivo geral deste projeto é desenvolver um modelo de Inteligência Artificial utilizando o Framework Scikit-Learn, amplamente empregado para modelagem preditiva e análise de dados (PEDREGOSA, 2011), sendo capaz de classificar e prever o desempenho de candidatos com base em seu perfil socioeconômico extraído dos Microdados do ENEM 2023.

Os objetivos específicos incluem:

- **Extrair e tratar** os microdados do ENEM 2023, filtrando variáveis críticas como renda (Q006), escolaridade dos pais (Q001/Q002) e acesso tecnológico (Q024/Q025);
- **Realizar análise exploratória (EDA)** para validar as correlações entre vulnerabilidade social e médias de notas;
- **Construir um pipeline de dados** em Python para a limpeza e normalização dos atributos categóricos do questionário socioeconômico;
- **Implementar e treinar** algoritmos de regressão ou classificação para estimar a nota final dos candidatos;
- **Avaliar a precisão do modelo** e discutir os impactos éticos da predição algorítmica em contextos sociais.

2. O Problema

A disparidade no desempenho acadêmico entre diferentes estratos sociais no Brasil configura um desafio estrutural para o sistema educacional (ALVES; SOARES, 2013). Embora o ENEM produza um volume massivo de dados anualmente, a identificação manual de perfis de vulnerabilidade é ineficiente e reativa (BERNARDES; FILHO, 2023). O problema central reside na dificuldade de isolar e quantificar o peso real de variáveis extracurriculares, como renda e capital cultural familiar, sobre a nota final do candidato (MELO *et al.,* 2021).

Desta forma, a questão norteadora desta pesquisa é: "Quais variáveis socioeconômicas apresentam maior relevância estatística na predição de um desempenho abaixo da média e como modelos de Machine Learning podem automatizar a identificação desses grupos de risco para apoiar ações de equidade pedagógica?"

3. Ética e Responsabilidade

O desenvolvimento desta solução de Inteligência Artificial pauta-se nos princípios de transparência e justiça algorítmica, conforme os seguintes pilares:

- Privacidade e Conformidade: O projeto utiliza os Microdados do ENEM 2023, que já foram submetidos a processos de desidentificação e anonimização pelo INEP. O tratamento dos dados respeita integralmente a Lei Geral de Proteção de Dados (LGPD), garantindo que nenhum participante possa ser reidentificado através do cruzamento de variáveis.
- Mitigação de Viés Algorítmico: Reconhece-se o risco de o modelo reproduzir preconceitos históricos (MEHRABI *et al.,* 2021). Para mitigar isso, o algoritmo será auditado através de métricas de justiça (*Fairness*), garantindo que a ferramenta funcione como um mecanismo de auxílio e promoção de equidade, e nunca como um critério de exclusão ou rotulagem discriminatória de estudantes.
- Responsabilidade Social: A saída do modelo é interpretada como um indicador de necessidade de suporte, visando o direcionamento de recursos para onde a vulnerabilidade social mais impacta o aprendizado.

4. Dados e Metodologia

A metodologia aplicada nesta fase inicial compreende a estruturação do pipeline de dados e a validação de hipóteses por meio de análise estatística descritiva.

4.1. Fonte de Dados e Extração

Os dados foram extraídos dos Microdados Oficiais do ENEM 2023 (INEP). Devido à volumetria do arquivo original (MICRODADOS_ENEM_2023.csv), foi aplicada uma técnica de amostragem aleatória () para garantir a viabilidade do processamento computacional sem perda de representatividade estatística.

4.2. Seleção de Atributos (*Feature Selection*)

Para a construção do modelo preditivo, foram selecionadas variáveis que compõem o ecossistema socioeconômico do candidato:

- **Capital Cultural:** Q001 e Q002 (Escolaridade do pai e da mãe).
- **Capacidade Econômica:** Q006 (Renda familiar mensal).
- **Inclusão Digital:** Q025 (Existência de acesso à rede mundial de computadores).
- **Contexto Institucional:** TP_ESCOLA (Diferenciação entre ensino público e privado).
- **Variáveis Alvo (*Target*):** Notas padronizadas por área de conhecimento e média geral.

4.3. Análise Exploratória de Dados (EDA)

A Figura 1 apresenta a distribuição da nota média dos candidatos em função da renda familiar mensal, utilizando a técnica estatística de *boxplot*. Para garantir a

integridade da análise, foram filtrados apenas os candidatos presentes em todas as etapas do exame, e os *outliers* foram omitidos visualmente para focar na tendência das medianas.

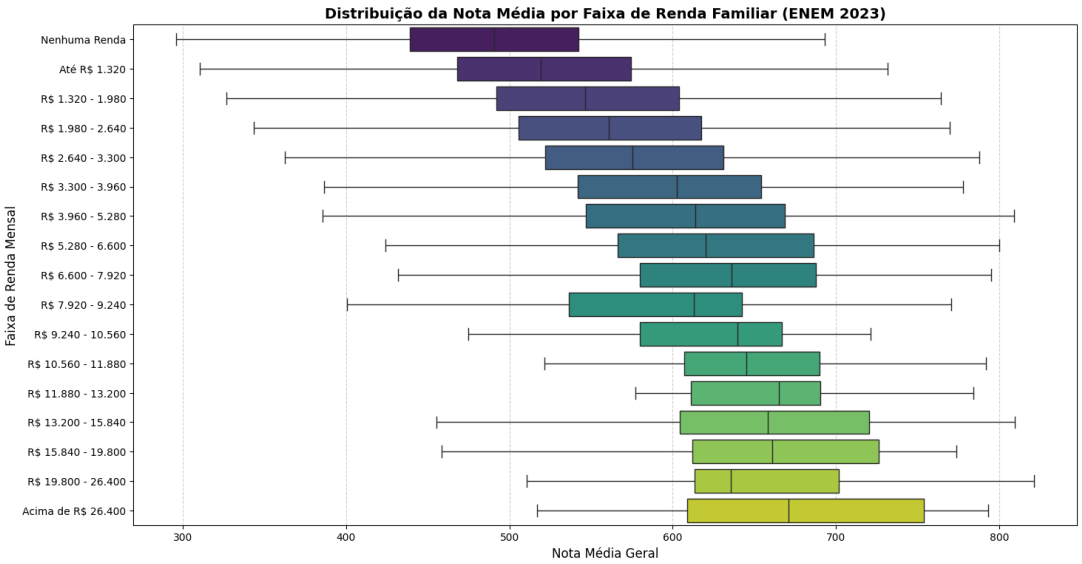

Figura 1: Impacto da Renda Familiar no Desempenho Médio (ENEM 2023)

5. Análise dos Resultados

A visualização revela uma correlação positiva direta e proporcional entre o nível socioeconômico e o desempenho acadêmico. Observa-se que:

- Tendência Linear: Existe um deslocamento progressivo da mediana das notas para a direita à medida que a faixa de renda aumenta. Enquanto candidatos na faixa de "Nenhuma Renda" apresentam uma mediana próxima a 450 pontos, candidatos na faixa "Acima de R$ 26.400" superam a marca de 650 pontos.
- Disparidade Educacional: A amplitude entre a menor e a maior média de renda evidencia o "abismo" educacional discutido na introdução deste trabalho, confirmando a renda familiar como um dos preditores de maior peso para o modelo de Inteligência Artificial.
- Variabilidade: Nota-se que, em faixas de renda mais baixas, o intervalo interquartil (a largura da caixa) é levemente mais comprimido em notas menores,

sugerindo um teto de desempenho imposto pela escassez de recursos, enquanto faixas mais altas mostram maior concentração em níveis de excelência.

Este cenário ratifica a importância do desenvolvimento de um modelo preditivo que permita a identificação antecipada dessas vulnerabilidades, contribuindo para a implementação de políticas públicas mais direcionadas e eficazes na mitigação dos fatores que impactam negativamente o desempenho de grupos em situação de desvantagem socioeconômica.

6. Referências bibliográficas

ALVES, Maria Teresa Gonzaga; SOARES, José Francisco. Efeitos de escolas e municípios na qualidade do ensino fundamental. Cadernos de Pesquisa, São Paulo, v. 43, n. 149, p. 492–517, 2013. DOI 10.1590/S0100-15742013000200007. Disponível em: https://www.scielo.br/j/cp/a/WGhPXprTVJRhtZKc5VVrsdN. Acesso em: 20 mar. 2026.

BARROS, Ricardo Paes de; MENDONÇA, Rosane; SANTOS, Daniel Domingues dos; QUINTAES, Giovani. Determinantes do desempenho educacional no Brasil. Brasília: Pesquisa e Planejamento Econômico, v. 31, n. 1, 2001. Disponível em: https://repositorio.ipea.gov.br/entities/publication/c6ab3d02-b223-4600-a37b-9199a2c78769. Acesso em: 22 mar. 2026.

BERNARDES, Rafael Victor Araujo; FILHO, Renato Miranda. Análise de padrões e tendências socioeconômicas no ENEM (2019–2023) por meio de clusterização. Sabará, MG: Instituto Federal de Educação, Ciência e Tecnologia de Minas Gerais, 2023. Disponível em: https://repositorio.ifmg.edu.br/server/api/core/bitstreams/29e33d45-fdb0-404b-8811-78935461a7c4/content. Acesso em: 24 mar. 2026

BONAMINO, Alicia et al. Os efeitos das diferentes formas de capital no desempenho escolar: um estudo à luz de Bourdieu e de Coleman. Rio de Janeiro: Revista Brasileira de Educação, v. 15, n. 45, p. 487-499, 2010. DOI 10.1590/S1413-24782010000300007.

Disponível em: https://www.scielo.br/j/rbedu/a/GbzRVcsL7L6PVNx3mxtdFkQ. Acesso em: 22 mar. 2026.

BRASIL, Instituto Nacional de Estudos e Pesquisas Educacionais (INEP). Enem 2025: mais de 4,8 milhões de inscritos confirmados. Brasília, DF: INEP, 2025. Disponível em: https://www.gov.br/inep/pt-br/centrais-de-conteudo/noticias/enem/enem-2025-mais-de-4-8-milhoes-de-inscritos-confirmados. Acesso em: 18 mar. 2026.

BRASIL, Instituto Nacional de Estudos e Pesquisas Educacionais (INEP). Microdados do Enem 2023. Brasília, DF: INEP, 2024. Disponível em: https://www.gov.br/inep/pt-br/acesso-a-informacao/dados-abertos/microdados/enem. Acesso em: 18 mar. 2026.

MEHRABI, Ninareh et al. A Survey on Bias and Fairness in Machine Learning. *ACM Computing Surveys*, 2021. DOI 10.1145/3457607. Disponível em: https://dl.acm.org/doi/10.1145/3457607. Acesso em: 23 mar. 2026.

MELO, Rafael Oliveira et al. Impacto das variáveis socioeconômicas no desempenho do Enem: uma análise espacial e sociológica. Revista de Administração Pública, v. 55, n. 6, p. 1271–1294, 2021. DOI 10.1590/0034-761220200843. Disponível em: https://repositorio.usp.br/item/003216116. Acesso em: 24 mar.2026

PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 2011. Disponível em: https://jmlr.csail.mit.edu/papers/v12/pedregosa11a.html. Acesso em : 18 mar. 2026.